

Çelik Levha Kusur Türlerinin Yapay Zeka ile Sınıflandırılması

Hazırlayan: Serdar Önal (İnşaat Mühendisi & Veri Bilimci)

Tarih: 30 Mayıs 2026

Proje Durumu: Final Teslimatı (0.88529 Private AUC Skoru)

1. Problem Tanımı ve Proje Hedefleri

Çelik üretim süreçlerinde yüzey kusurlarının doğru sınıflandırılması, kalite standartlarının korunması ve maliyet optimizasyonu açısından kritik bir mühendislik problemidir. Bu projenin temel hedefleri şunlardır:

- Otomatik Kusur Tespiti:** Manuel kontrol süreçlerini dijitalleştirmek.
- Hassas Sınıflandırma:** 7 farklı kusur türünü birbirinden ayırt etmek.
- Endüstriyel Otomasyon:** Gerçek zamanlı üretim hatlarına entegre edilebilir bir karar destek sistemi kurmak.

2. Özellik Mühendisliği (Feature Engineering) Derin Analizi

Modelin başarısının arkasındaki temel faktör, veriden türetilen yeni "taşıyıcı" değişkenlerdir:

- Geometrik Analiz (Aspect_Ratio & Area_Perimeter_Ratio):** Kusurların ince çizik mi yoksa geniş bir yüzey deformasyonu mu olduğunu belirler.
- Parlaklık Analizi (Luminosity_Range & Luminosity_Density):** Yüzeydeki doku farklılıklarını ve leke yoğunluklarını ölçer.
- Kritik Değişken (Outside_Global_Index):** Karar mekanizmasında %30'dan fazla ağırlığa sahip olup genel yüzey anomalilerini yakalayan en önemli değişkendir.


3. Model Mimarisi ve Eğitim Stratejisi

- Ana Algoritma:** XGBoost Multi-Class Classifier.
- Neden XGBoost?** Tabular verilerdeki üstün başarısı, gürültüye (noise) karşı toleransı ve hızlı optimizasyon yeteneği nedeniyle tercih edilmiştir.
- Doğrulama (Validation):** Model, **Stratified Cross Validation** yöntemiyle eğitilmiş; eğitim ve doğrulama eğrileri arasındaki denge gözetilerek "ezberleme" (overfitting) riski minimize edilmiştir.

4. Teknik Bulgular ve Görsel Analiz


Aşağıdaki grafikler modelin performans belgeleridir:

4.1. Modelin Karar Mekanizması




Modelin en kritik 15 özelliği incelendiğinde, geometrik indekslerin ve parlaklık verilerinin sınıflandırmada dominant rol oynadığı görülmektedir.

4.2. Öğrenme ve Başarı Grafikleri



Öğrenme eğrisi, modelin düşük bias ve kontrollü variance ile ideal bir genelleme kapasitesine ulaştığını kanıtlamaktadır.



Karışıklık matrisi, modelin özellikle hangi sınıflarda (örn: Bumps vs Other Faults) zorlandığını açıkça ortaya koymaktadır.

5. Hata Analizi ve Mühendislik Yorumu

Modelin performansını sınırlayan temel faktörler şunlardır:

- **Doku Karmaşası:** Model, nesne formundan ziyade doku ve renk özelliklerine ağırlık vermektedir.
- **Sınıf Örtüşmesi:** Bumps ve Other Faults arasındaki düşük sınıf ayrımı, sensör yoğunluklarının örtüşmesinden kaynaklanmaktadır.
- **Çözüm:** Gelecek aşamalarda **Görsel tabanlı CNN hibrit yaklaşımı** ile bu doku karmaşasının aşılması hedeflenmektedir.

6. İş Değeri ve Gelecek Vizyonu

Geliştirilen bu sistemin endüstriyel faydaları:

1. İnsan hatasından kaynaklı maliyetlerin düşürülmesi.
2. Müşteri memnuniyetini artıran yüksek standartlı kalite kontrolü.
3. **Streamlit Dashboard** entegrasyonu ile fabrika ortamında anlık analiz imkanı.

Gelecek Planı: LightGBM ve CatBoost benchmark çalışmaları ile modelin güçlendirilmesi ve SHAP analizleri ile açıklanabilir yapay zeka (XAI) standartlarına taşınması planlanmaktadır.
